Heterogeneous-Arrow: modéliser le rythme du Data-Flow

Modélisation du rythme de traitement et du changement de structure des flux dans un contexte Data-Flow

Gautier DI FOLCO

INRIA, équipe DICE, gdifolco@ens-lyon.fr

Résumé Le *Data-Flow* est un outil de programmation permettant d'exprimer des flux de données circulant entre des entités d'exécutions. Après avoir présenté ses usages et ses enjeux, nous montrons, à l'aide d'un cas pratique, une faiblesse dans le modèle actuel qui réside dans la difficulté de composer des contextes de calculs différents. Nous fournissons une généralisation des **Arrows** en Haskell.

Abstract. The *Data-Flow* is a tool that allow us to express data flows traveling between execution entities.

We will show its goals, then we will expose a weakness in the current design, that is hard to compose different computational context. We will provide a generalisation of Haskell Arrows .

1 Introduction

Le Data-Flow modélise le "continu" dans les programmes informatiques. Ce qui permet par exemple de décrire des animations graphiques sous l'aspect de formules mathématiques sans gérer la manière dont elles seront interprêtées. Les formules étant exprimées selon des variables continues, elles seront ensuite automatiquement discrétisées pour le rendu visuel. Du fait que le continu est représenté par une infinité de valeurs entre deux bornes, il en découle une notion d'infini, les bornes étant inacessibles. Ce qui force le calcul sur des données incomplètes entrainant des calculs partiels.

Cette notion d'incomplétude des données est utilisée pour répondre à un problème de charge de traitements. Par exemple l'afflux de données provenant de l'Internet a tellement augmenté qu'il devient trop coûteux en ressources de lancer un calcul donné sur l'ensemble des données. De plus, lorsqu'on modélise un flux, il est déjà existant, donc nous n'avons pas accès au début et le flux n'a pas de fin. Ainsi des calculs partiels sont effectués et complétés au fur et à mesure de la réception de nouvelles données.

Notre objectif est de proposer des outils pour manipuler des flux ayant des rythmes et des structures différents explicitement modélisés.

2 Historique

Nous exposons l'historique des langages *Data-Flow* afin de mettre en avant l'importance du rythme dans les systèmes *Data-Flow*.

Strachey [16] décrit en 1973 l'état du monde de la programmation informatique, en opposant deux paradigmes : la programmation fonctionnelle et impérative.

L'une des premières implantation du *Data-Flow* [6] réalisée en 1972 est présentée comme une généralisation de LISP, un langage fonctionnel.

Le *Data-Flow* est défini par Dennis et al. [6] comme un modèle dont l'exécution est déclenchée par la disponibilité des données. Il y a une dépendance explicitement modélisée du code vis-à-vis des données.

2.1 Réseaux de Kahn

Kahn [12] fournit un langage en 1974 pour effectuer des calculs en parallèle, où les programmes sont découpés en entités communiquant entre elles via des channels, qui sont des listes FIFO infinies ayant une taille de tampon fixe.

2.2 Prémisses de la modélisation du continu avec le *Flow-based* programming

Lucid (1976) [2] modélise l'infini en se basant sur les suites mathématiques, c'està-dire par une valeur de départ et un code pour calculer les valeurs suivantes.

Une notion de temps a été ajoutée au flux par Esterel (1984) [4]. Les programmes sont proches des filtres UNIX : ils n'ont qu'une entrée auxquels ils réagissent sur leur sortie.

Les flux sont considérés comme un ensemble et plus comme un flux unique dans Signal (1985) [3]. Ce qui permet, comme dans StreamIT (2002) [17], de mettre en relation des flux pour en créer de nouveaux.

Les programmes sont des graphes acycliques orientés, où les noeuds représentent des algorithmes élémentaires et les arcs les dépendances sur les données, comme dans Lustre (1987) [5].

2.3 L'avènement des environnements interactifs avec le Reactive-based programming

TBAG (1994) [10] introduit la notion de variation temporelle. De manière graphique l'utilisateur va définir un ensemble de relations entre les objects qui vont varier au cours du temps. TBAG se charge d'évaluer ces relations pour des valeurs temporelles significatives afin que l'animation semble avoir été calculée depuis un flux continu.

Par la suite, Media Flow (1995) [9] va permettre la combinaison visuelle de flux continus. Functional Reactive Animation (Fran, 1997-1998) [8] [7] s'appuie sur une spécification programmatique des relations entre des objets en fonction du temps. Il effectue ensuite son rendu graphique dynamiquement.

Fran est le point de départ de nombreux papiers comme RT-FRP (2002) [19] qui ajoute un aspect temps-réel ou Nilsson et al. (2002)[15] qui se base sur la déclaration de l'enchaînement des traitements.

Le Functional reactive programming considère, comme dans André (1996) [1], les programmes comme une réaction à un ensemble de signaux. Un signal perçu déclenche l'exécution d'un comportement, le programme réagit à un principe de stimuli.

2.4 Conclusion

La hausse du volume de données générées, échangées, traitées et stockées augmente de plus en plus.

Notre hypothèse est que les moyens de traitement et de stockage ne sont plus suffisants.

Nous devons mettre en place des mécanismes pour permettre de diminuer la charge de traitements à effectuer.

Le choix que nous avons fait est de considérer que l'information n'est pas complète. Nous n'en possédons pas la fin, et nous ne possédons souvent pas le début.

Ainsi, nos calculs sont effectués sur une information incomplète, ce qui nous donne un calcul partiel. Lorsque nous avons une nouvelle information, nous reprenons le résultat précédemment calculé pour le compléter avec la nouvelle donnée

Il y a une diminution du nombre de calculs, puisque ceux-ci ne sont effectués que partiellement.

3 Modélisation du rythme et de la structure des flux

3.1 Rythme et nature du flux

Nous appelons nature d'un flux la méthode de construction des données sortantes. Par exemple, le fait d'aggréger les informations d'un flux à un autre change sa nature car nous obtenons une donnée qui dépend de son historique à partir d'une donnée unitaire.

Le rythme est modifié si, par exemple, le calcul est lancé uniquement toutes les N nouvelles données, le flux de sortie aura N fois moins de messages que le flux d'entrée.

3.2 Cas pratique : box office

Nous disposons d'un flux de tickets de cinéma. Un ticket est identifié par un nom de film.

Nous souhaitons avoir un premier flux contenant une liste de films ordonnés par nombre d'entrées décroissant, obtenu via un noeud genRanking. Ce qui implique un changement de nature du flux. Le rythme du flux ne change pas puisque la liste est mise à jour à chaque nouveau ticket.

À partir de ce flux, nous voulons limiter le débit en le divisant par 3 pour que la donnée puisse être affichée de manière stable, obtenu via un noeud stabilize. Nous opérons un changement de rythme.

3.3 Mise en oeuvre avec Haskell

Haskell [14] est un langage purement fonctionnel non-strict. Nous l'avons choisi car il est le support de nombreuses approches à la fois *Reactive-based programming* et en *Functional reactive programming* et qu'il dispose d'un système de types assez avancé pour modéliser notre domaine d'étude.

Modélisation sans notion de rythme La méthode classique pour gérer le Data-Flow en Haskell sont les Arrows [11].

Nous verrons successivement différents concepts afin de gérer la composition de noeuds de calculs sans notion de rythme. Les concepts sont implantés via des typeclass qui représentent la capacité à appeler un ensemble de fonctions sur un ensemble de type de données. Il s'agit d'un mécanisme proche des templates spécialisées du C++.

Dans un premier temps nous arrêterons sur la notion de fonctions puisque les calculs sont effectué en leur sein. Ensuite viendra les Category qui définissent la relation de composition pour un type donné. Nous étudierons les Arrows qui founrissent un moyen de composition plus avancé. Nous présenterons les Monads afin d'obtenir un état persistent. Nous combinerons Arrows et Monads pour obtenir un calcul à états, ce qui nous donnera un Kleisli Arrow dont le résultat de l'évaluation d'une même donnée varie au court du temps.

Définition des fonctions En Haskell, tout est expression, le type d'expressions le plus courant est le type fonction noté ->. Il est fourni par le langage. Sa pseudo déclaration est la suivante :

```
data i -> o = ...
```

Il a un paramètre de type i en entrée et retourne une valeur de type o. Le type d'une fonction f attendant un entier, noté Int, et produisant un caractère noté Char sera noté :

```
1 f :: Int -> Char
```

Les types de données sont nommés par une lettre commençant en majuscule. Les types de données commençant en minuscule sont des types qui seront déterminés en fonction de leur(s) usage(s), comme les *templates* C++. Lorsque deux types commençant en minuscule sont les mêmes, le type assigné à l'usage sera le même.

```
1 f :: a -> a -- Definition
2 f :: Int -> Int -- Legal
3 f :: Char -> Char -- Legal
4 f :: Char -> Int -- Illegal
```

Pour qu'une fonction prennent plusieurs arguments, il faut que, conceptuellement, à chaque nouvel argument appliqué, elle retourne une nouvelle fonction. Ainsi, les fonctions suivantes ont le même type :

```
1 f :: a -> b -> c -> d -> e g :: a -> (b -> (c -> (d -> e)))
```

On parle de currification ou currying.

Définition de la composabilité avec les Category Ici nous déclarons le *ty*peclass Category, qui représente la notion de composabilité.

```
class Category cat where
id :: cat a a
(.) :: cat b c -> cat a b -> cat a c
```

Pour un type arbitraire cat, une fonction id et un opérateur (.) lui sont associés.

La fonction id, représente l'identité, c'est à dire que cat a ses deux paramètres de même type, le type a.

L'opérateur de composition (.) qui crée une Category ayant pour types paramétriques a c en redirigeant la sortie d'une Category b c vers l'entrée d'une Category a b.

Les fonctions classiques sont nommées avec des caractères alphanumériques et commencent toujours par une minuscule. Les opérateurs ne sont composés que de caractères non-alphanumériques.

La différence entre les deux est visible au niveau de la position par défaut lors de l'appel. Les fonctions classiques ont une position préfixe :

```
1 add 4 5
```

add est une fonction classique, elle est placée devant ses arguments. Les opérateurs ont une position infixe :

```
1 4 + 5
```

+ est un opérateur, il est placé entre ses deux premiers arguments.

Nous pouvons changer la position des fonctions classiques et des opérateurs en les entourant, respectivement, de *back-quotes* (') et de parenthèses. Ainsi, voici l'équivalent des deux exemples précédents en inversant les positions :

```
1 4 'add' 5 (+) 4 5
```

Cette distinction est importante car, lorsque nous mentionnons une fonction en position préfixe et que nous omettons un ou plusieurs de ses dernier arguments, une fonction est automatiquement créée, grâce au *currying*. Cette fonction aura pour paramètres, les paramètres omis. On parle d'application partielle. Comme nous l'avons vu plus haut, de manière plus général, en Haskell, toutes les fonctions n'attendent qu'un argument et ne renvoient qu'une valeur. Ainsi, conceptuellement, lorsqu'une fonction attend plusieurs arguments, lors de chacun de ses appels, une nouvelle fonction est retournée :

```
1 add :: Int -> Int -> Int 2 add 4 :: Int -> Int 3 add 4 5 :: Int
```

Ici, il y a donc création de trois fonctions : une fonction d'addition générale, une fonction qui ajoute 4 à un nombre et une fonction constante.

Alors que les fonctions en position préfixes créent automatiquement des fonctions lorsqu'elles ne sont que partiellement appliquées, si un des deux premiers arguments manquent à un opérateur, une erreur de syntaxe est levée. Les exemples suivants ne sont pas syntaxiquement valides :

```
1 'add'
2 'add' 5
3 4 'add'
4 +
5 + 5
6 4 +
```

Pour les rendres valides, il faut les entourer de parenthèses :

```
1  ('add')
2  ('add' 5)
3  (4 'add')
4  (+)
5  (+ 5)
6  (4 +)
```

C'est la raison pour laquelle, lorsque l'on déclare le type d'un opérateur, comme l'opérateur de composition (.), nous sommes obligés de le parenthéser, puisque nous ne lui passons aucune valeur.

Un exemple d'instance de Category concerne le type des fonctions. Le type fonction est un type à part entière noté (->). Ainsi, à partir de la déclaration du typeclass Category, nous remplaçons toutes les occurences de cat par (->).

```
instance Category (->) where
    -- Version prefixe : id :: (->) a a
    -- Version infixe : id :: a -> a
    id x = x

-- Version prefixe : (.) :: (->) b c -> (->) a b -> (->) a c
    -- Version infixe : (.) :: (b -> c) -> (a -> b) -> (a -> c)
```

id, ligne 4, attend un argument x et le retourne. Le type de x est quelconque, noté a, et le type de retour de id est le même que le type de son paramètre, soit a.

(.), ligne 8, attend deux fonctions pour en produire une troisième. Son premier argument, f, est une fonction attendant un type quelconque noté b et renvoyant un type quelconque c, le tout est noté b -> c. Son second argument, g, est une fonction attendant un type quelconque noté a et renvoyant un type quelconque b, le tout est noté a -> b. (.) crée une lambda expression, une sorte de fonction anonyme, via \x -> attendant un paramètre x. Il applique ce paramètre à la fonction g, via g x. Puis le résultat de cette application sera appliqué à la fonction f. Par conséquent, la fonction résultante aura un paramètre du type de celui de la fonction g, ie. a, et un type de retour de sa fonction f, ie. c. Donc, c'est une fonction qui prend deux fonctions, l'une prenant un a et renvoyant un b, l'autre prenant un b et renvoyant un c. Elle renvoie une fonction prenant un a et renvoyant un c, qui est bien la notion de composition.

Par exemple, si nous disposons de deux fonctions add3 et prod2, qui, respectivement, ajoute 3 à un nombre et le multiplie par 2, nous pouvons les combiner de la manière suivante :

```
1 add3 :: Int -> Int
2 add3 x = x + 3
3
4 prod2 :: Int -> Int
5 prod2 x = x * 2
6
7 prod2Add3 :: Int -> Int
8 prod2Add3 = add3 . prod2
```

Ainsi prod2Add3 1 renvoie 5. Nous aurions pu l'ecrire prod2Add3 x = prod2(add3 x). En fait il se passe le mécanisme de substitution, appelé évaluation, suivant :

```
prod2Add3 = add3 . prod2
1
    -- f \cdot g = \langle x - \rangle f (g x)
    -- f est remplace par add3 et g par prod2
   prod2Add3 = \x -> add3 (prod2 x)
    -- lorsque 1 est applique a prod2Add3 :
6
   prod2Add3 1
7
    (\x -> add3 (prod2 x)) 1
8
    -- x est remplace par 1
9
    add3 (prod2 1)
10
    add3 (1 * 2)
   add3 2
11
12
   2 + 3
   5
13
```

Pour représenter le box office présenté enn introduction, nous modélisons la notion de noeud de calcul par un type de données Node.

```
data Node a b = Node { process :: a -> b }
```

Il contient une fonction transformant un a en un b, ces types étant les types paramétriques de Node.

Le mot clef data permet de définir de nouveaux types de données. Il est suivi de l'identifieur de type, qui commence toujours par une lettre majuscule lorsqu'il est alphanumérique, ici Node. Il peut être ensuite suivi d'un ou plusieurs paramètres de types, ici a et b. L'identifieur de type est utilisé uniquement dans les déclarations de types.

Ensuite, après le = viennent le ou les constructeurs, ici Node. Ils suivent les mêmes conventions de nommage que les identifieurs de types, mais l'identifieur de type et le constructeur n'ont pas obligatoirement le même nom. Un construteur peut attendre des valeurs ou non, ici il attend une fonction de type a -> b. process est une fonction créé automatiquement, elle a le type Node -> a -> b.

Node peut se manipuler de la manière suivante :

```
1 -- Pour : f :: Int -> Char
2 Node f :: Node Int Char
3 4 process' :: Node a b -> a -> b -- equivalent de process
5 process' (Node f) = f
```

Nous définissons ensuite les fonctions nécessaires pour que Node soit une instance du typeclass Category, ligne 2 et 3.

```
instance Category Node where
id = Node id
(Node g) . (Node f) = Node (g . f)
```

Nous n'avons pas besoin d'indiquer le type des fonctions, Haskell le déduit automatiquement via *typeclass* qu'il implante. id, ligne 2, est un appel au constructeur Node avec la fonction générique id. Ainsi le type de cette fonction est Node a a.

L'opérateur de composition, ligne 3, extrait par déconstruction, filtrage par motifs ou *pattern matching*, les valeurs du constructeur de Node de chacun de ses argument. g et f sont deux fonctions qui sont recomposées au sein d'un nouveau Node.

Ensuite viennent les types plus spécifiques à notre problème :

```
data Rank = Rank { title :: String, visitors :: Int }
    deriving (Show, Eq)

type Ticket = String
type Counter = Int
type Ranking = [Rank]
```

Ici, nous définissons un type Rank, ligne 1, composé d'une chaine de caractère, String, et d'un entier, Int. Nous demandons au compilateur d'instancier automatiquement deux *typeclass*: Show, pour pouvoir afficher les valeurs et Eq.

pour faire des comparaisons entre deux valeurs. Le compilateur est en mesure de déduire les implantations naives pour un certain nombre de typeclass.

Puis, trois alias de types: Ticket, Counter et Ranking qui sont, respectivement, les alias de String, Int et de [Rank]. Les alias ne font qu'améliorer la lisibilité des types, ils n'influent pas sur la compilation ou l'exécution.

[Char] représente une liste de Char. Il est défini de la manière suivante :

```
1 data [] a = [] | a : [a]
```

Le type liste est composé de deux constructeurs, séparés par un 1. Le premier, ligne 1, [], ne prend aucun valeur et représente l'élément liste vide. Le second, ligne 2, est l'opérateur (:), qui attend deux arguments : le premier est une valeur de type a et le second est une autre liste de type a, noté [a]. Il s'agit d'un type récursif puisqu'un de ses constructeurs a un de ses paramètres de son propre type.

Nous implémentons un noeud stabilize qui limite le débit d'un flux. Pour cela nous avons besoin d'une valeur quelconque et d'un compteur en entrée, nous utilisons une paire a, Int. Le noeud produit une nouvelle valeur pour le compteur et peut-être une valeur, en fonction de l'état de son compteur.

La possibilité de présence ou de l'absence d'une valeur est représenté par le type suivant :

```
1 data Maybe a = Nothing | Just a
```

Le constructeur Nothing, ligne 1, représente l'absence de valeur. Tandis que Just, ligne 2, représente la présence d'une valeur de type a qu'il contient.

Nous implémentons stabilize de cette manière :

```
stabilize :: Node (a, Counter) (Maybe a, Counter)
stabilize = Node (\ (x, i) -> if i < 2
then (Nothing, i + 1)
else (Just x, 0))</pre>
```

Nous faisons appel au constructeur Node, ligne 2, en lui fournissant une lambda expression. Celle-ci possède un paramètre qui doit être une paire d'une valeur de type arbitraire nommée x et un Counter nommé i, soit le type (Maybe a, Counter).

Si le compteur, i, est inférieur à 2, nous renvoyons, ligne 3, une paire dont le premier élément est Nothing, car nous souhaitons ne renvoyer qu'une valeur sur 3, et nous incrémentons le compteur i. Si non, ligne 4, nous renvoyons une paire contenant la valeur et nous remettons le compteur à 0.

L'implantation des noeuds genRanking qui met à jour un classement nécessite un classement et un ticket et un classement pour générer un nouveau classement. Comme pour stabilize, genRanking attend une paire en entrée, comprenant un Ticket et un Ranking et produira un Ranking.

```
genRanking :: Node (Ticket, Ranking) Ranking
```

updateRanking attend un Ticket t et un Ranking r.

La fonction break est appelée à la ligne 5. Son rôle est de, à partir d'une fonction renvoyant un booléen en fonction d'un élément de son second paramètre, une liste, ici les Ranks r, parcourir sa liste, de gauche à droite et lorsque la fonction passée renvoie True, générer une paire de tableau dans lequel son premier membre sera l'ensemble des éléments déjà parcourus et son membre de gauche sera le tableau contenant l'élement courant et le reste de la liste. La fonction donnée à break renvoie True lorsque le titre du film i de l'élément courant est égale au titre du film sur le Ticket t. Le résultat de break est séparé en a et b.

Nous distinguons deux cas pour b.

S'il est vide, ligne 3, [], c'est que c'est le premier Ticket pour un film. Dans ce cas, nous ajoutons le film avec une entrée à la fin du Ranking.

Si non, ligne 4, nous extrayons le premier élément de b dans x et le reste de la liste dans xs. x est le Rank correspondant au film de notre Ticket. Nous ajoutons la première partie de la liste a, au reste de la liste xs au Rank incrémenté, puis nous trions le tout pour obtenir un Ranking ordonné.

Si nous souhaitons composer ces deux noeuds nous sommes dans l'incapacité de le faire car le type de sortie de genRanking n'est pas le même que le type d'entrée de stabilize :

```
genRanking :: Node (Ticket, Ranking) Ranking
stabilize :: Node (a, Counter) (Maybe a, Counter)
```

Comme nous l'avons vu le type de >>> est le suivant :

```
1 (.) :: cat b c -> cat a b -> cat a c
2 -- Soit
3 (.) :: Node b c -> Node a b -> Node a c
```

Nous voulons composer stabilize et genRanking. Si nous substitutons les types, c devient le type de sortie de stabilize, soit (Maybe a, Counter) et a devient le type d'entrée de genRanking soit (Ticket, Ranking).

Il nous reste à substituer c, qui doit être à la fois le type de sortie de genRanking et le type d'entrée de stabilize. Mais genRanking à pour type de sortie Ranking et stabilize à pour type d'entrée (a, Counter), les deux types n'étant pas les mêmes, (.) ne peux pas être appliqué directement à ces fonctions.

Category ne permet pas la composition dans ce cas.

Standardisation des compositions avec les Arrows Les Arrows [11] ont été introduits pour pouvoir combiner de manière standard des fonctions au sein d'une Category. Il s'agit d'une spécialisation des Category. Les Arrows sont définis en Haskell via le *typeclass* suivant :

```
1 class Category a => Arrow a where
2 arr :: (b -> c) -> a b c
3 first :: a b c -> a (b, d) (c, d)
4 second :: a b c -> a (d, b) (d, c)
5 (***) :: a b c -> a b' c' -> a (b, b') (c, c')
6 (&&&) :: a b c -> a b c' -> a b (c, c')
```

Ici la fonction arr construit un type de données a b c à partir d'une fonction b -> c. Typiquement il s'agit de stocker la fonction dans un type de données.

first et second changent le type d'entrée et de sortie en paire ayant un membre, d, supplémentaire. Cette valeur a un type quelconque et sera simplement recopiée lors de l'évaluation du calcul. Cette valeur se situe en seconde position de la paire pour first et en première position de la paire pour second.

*** aggrége deux calculs qui seront effectués sans interaction l'un avec l'autre.

&&& crée un calcul qui applique un même argument à deux calculs ayant le même type d'entrée et retournera ensuite leur résultat respectif dans une paire.

De plus deux opérateurs de composition sont introduits :

```
1 (>>>) :: Category cat => cat a b -> cat b c -> cat a c
2 (<<<) :: Category cat => cat b c -> cat a b -> cat a c
```

<< est un alias de l'opérateur de composition (.). >>> est aussi un alias mais dont les paramètres ont été inversés. Ce sont des fonctions qui dépendent d'un typeclass, mais qui n'en font pas partie, elles n'ont qu'une définition et ne sont pas spécialisables par type.

Nous définissons ensuite les fonctions nécessaires pour que Node soit une instance du typeclass Arrow, ligne 2 et 3. Toutes les fonctions n'ont pas besoin d'être définies car certaines d'entre-elles disposent d'une implantation par défaut, qui repose sur d'autres fonctions du typeclass, dans la définition du typeclass.

```
instance Arrow Node where
arr = Node
first (Node f) = Node (\ ~(b, c) -> (f b, c))
```

arr, ligne 2, appel le constructeur de Node. Par currification, cela revient à écrire arr x = Node x.

first, ligne 3, extrait la fonction f de Node. Il crée un nouveau Node, dont la fonction est définie par une lambda expression. Celle-ci attend une paire et en renvoie une paire dont le second membre, c, sera inchangé, mais dont le premier, b, se voit appliqué à la fonction f.

Ainsi, si nous appliquons first à genRanking, nous obtenons un type de sortie compatible au type d'entrée de stabilize :

```
genRanking :: Node (Ticket, Ranking) Ranking
first genRanking :: Node ((Ticket, Ranking), a) (Ranking, a)
stabilize :: Node (a, Counter) (Maybe a, Counter)
```

Nous combinons ensuite ces noeuds pour n'en avoir qu'un seul, via la fonction de composition >>>:

Cette implantation pose problème car elle ne permet pas de construire un classement complet. genRanking voit sa sortie non-conservée si stabilize produit (Nothing, _). genRanking est donc limité par stabilize.

Il faudrait être en mesure de stocker un état qui conserverait le dernier classement généré. Malheureusement Haskell étant un langage fonctionnel pur, cela signifie qu'il dispose de la transparence référentielle, ainsi, toute fonction appelée avec les mêmes arguments donnera toujours le même résultat.

Gestion de l'état via les Monads Ainsi, un mécanisme nommé Monad [18] a été mis en place. Les Monads sont définies en Haskell via le typeclass suivant :

```
1 class Monad (m :: * -> *) where
2 (>>=) :: m a -> (a -> m b) -> m b
3 (>>) :: m a -> m b -> m b
4 return :: a -> m a
5 fail :: String -> m a
```

Ici on se place dans le cas d'un type de données m avec un paramètre m :: * -> *.

Par exemple la fonction return attend un paramètre de type quelconque \mathtt{a} et l'encapsule, transmet cette valeur à un constructeur, dans un type de donnée \mathtt{m} paramétré par le type de la valeur de son argument \mathtt{a} , il aura donc pour type de retour \mathtt{m} \mathtt{a}

L'opérateur important ici est >>=, il attend une valeur de type a dans un contexte m, soit le type m a, puis une fonction ayant un paramètre de type a et renvoyant une valeur de type b encapsulée dans le même contexte m que le premier argument de l'opérateur, la fonction attendue retourne une valeur de type m b. L'opérateur retourne ensuite une valeur de type m b. L'implantation naive consiste à renvoyer le retour de la fonction attendue à laquelle on a transmis la valeur de type a désencapsulée de son contexte m a.

Par exemple prenons le type de données ${\tt Maybe}$ vu plus haut dont la définition est la suivante :

```
data Maybe a = Nothing | Just a
```

Il nous faut ensuite définir l'instance Maybe du typeclass Monad :

```
instance Monad Maybe where
Just x >>= f = f x
Nothing >>= _ = Nothing

return x = Just x

a >> b = a >>= \_ -> b

fail _ = Nothing
```

Les lignes 2 et 3 définissent le corps de >>=. Par pattern matching, pour le constructeur Just, ligne 2, la valeur de retour sera la valeur de retour de la fonction \mathtt{f} à laquelle la valeur contenue par le constructeur, \mathtt{x} , lui aura été appliquée. Pour le constructeur Nothing, ligne 3, on ignore de le second argument \mathtt{h} et on renvoie Nothing.

return, ligne 5, prend une valeur et la passe au constructeur Just et le renvoie.

>>, ligne 7, appelle >>= en lui passant son premier paramètre puis en créant une lambda expression qui ignore son paramètre d'entrée et renvoie le second paramètre de >>.

fail, ligne 9, ignore son paramètre et renvoye Nothing.

Prenons l'exemple de cette fonction qui pour un entier donné, l'incrémente jusqu'à 3 puis renvoie Nothing.

```
1 addUntil3 :: Int -> Maybe Int
2 addUntil3 x = if x < 3
3 then Just (x + 1)
else Nothing</pre>
```

Notre objectif est de pouvoir chaîner les appels à cette fonction. Si nous faisons addUntil3 1 nous obtenons Just 2 du type Maybe Int. Impossible alors d'appeler directement la fonction sur ce résultat. Nous sommes obligés de sortir 2 de son contexte. C'est le rôle de >>=. Ainsi, addUntil3 1 >>= addUntil3 renverra Just 3. De plus, si nous l'appliquons encore, elle renverra toujours Nothing, sans que addUntil3 soit évaluée.

Nous pouvons réécrire addUntil3, 1 >>= addUntil3 en Just 1 >>= addUntil3 >>= addUntil3 puisque >>= extrait 1 de Just.

Si nous regardons l'implantation de l'interface, Just 1 >>= addUntil3 >>= addUntil3 et addUntil3 et addUntil3 peut être réécrit de cette manière :

Comme nous le voyons dans la signature addUntil3' n'est plus liée au type de donnée Maybe, à n'importe quelle type de données implantant le typeclass Monad.

Notre but à présent est de créer une Monad capable de stocker un état. Elle existe et se nomme la *State Monad* [13] et est définie de la manière suivante :

```
newtype State s a = State { runState :: s -> (a, s) }
```

State est un type qui n'aura pas d'existence réelle lors de l'exécution, newtype est un mot-clef permettant d'indiquer au compilateur qu'un type existe uniquement pour distinguer certaines expressions, sans qu'elles n'aient de structure particulière. Ainsi, State réprésente certaines expressions qui sont des fonctions prenant un état de type s et renvoyant une paire avec un état de type s et une valeur générée de type a.

L'implantation de l'instance de la Monad State est la suivante :

```
instance Monad (State s) where
return v = State (\s -> (v, s))
State v >>= f = State (\s -> let (a, b) = v s
in runState (f a) b)
```

Nous avons vu que Monad attendait des types ayant un et un seul paramètre. Or, State en possède deux. Pour être en mesure de définir l'instance Monad, nous utilisons la currification au niveau des types et nous fixons s, ligne 1, ce qui signifie que ce qui compte pour que State soit une Monad, c'est le type de son état.

return, ligne 2, prend une valeur, qui sera produite lors de l'exécution de la fonction représentée par State. Cette fonction se bornera à renvoyer l'état qui lui sera transmis.

>>=, ligne 3, récupère la fonction v de State. Il crée une nouvelle fonction dans State qui prend un argument d'état s, il sera appliqué à v, ce qui produira un couple (a, b) où a est la valeur produite et b le nouvel état. let fonctionne comme le where vu plus haut. Ensuite nous allons appliquer f à la valeur produite a, nous donnant un nouveau State. Nous appelons runState qui sort la fonction de State puis nous lui passons le nouvel etat b.

State possède également des fonctions pour rendre sa manipulation plus simple :

```
1    evalState :: State s a -> s -> a
2    evalState act = fst . runState act
3    
4    execState :: State s a -> s -> s
5    execState act = snd . runState act
```

evalState récupère le premier membre de la paire générée par l'exécution de la Monad, via la fonction fst. execState récupère le second membre de la paire générée par l'exécution de la Monad, via la fonction snd.

Il faut également des fonctions pour récupérer et assigner l'état :

```
1 get :: State s s
2 get = State (\x -> (x, x))
3
```

```
4 put :: s -> State s ()
5 put x = State (\_ -> ((), x))
```

Les cas d'utilisations sont les suivants :

```
1 runState (put 1) 2 -- ((),1)
2 runState get 2 -- (2,2)
```

Nous souhaitons créer une fonction qui récupère l'état courant, l'incrémente et produit la valeur initiale de l'état ajouté à lui-même. L'implantation est la suivante :

```
incrIncr :: State Int Int
incrIncr = do
    i <- get
    put (i + 1)
    return (i + i)</pre>
```

À la ligne 2, nous récupérons la valeur de l'état avec get, que nous représentons par i. Nous mettons ensuite sa valeur incrémentée dans l'état avec put à la ligne 3. Puis nous renvoyons l'état initial, i, ajouté à lui-même.

Cette notation est appelée do-notation et est en fait du sucre syntaxique pour :

```
incrIncr' :: State Int Int
incrIncr' = get >>= \i -> put (i + 1) >> return (i + i)
```

Les -> sont remplacés par des >>= \v -> et les retour à la ligne par des >>. Ainsi, runState incrIncr 2 génère (4, 3).

Nous pouvons les appliquer plusieurs fois pour que runState incr3 2 génère (8, 5).

```
1 incr3 :: State Int Int
2 incr3 = do
3    incrIncr -- (4, 3)
4    incrIncr -- (6, 4)
5    incrIncr -- (8, 5)
```

Nous pouvons réimplanter stabilize et genRanking en tant que State Monad :

```
1
   stabilize :: a -> State Counter (Maybe a)
2
   stabilize x = do
3
        i <- get
4
        if i < 2
5
        then put (i + 1) >> return Nothing
6
        else put 0 >> return (Just x)
7
   -- runState (stabilize 'a') 0
8
9
   -- => (Nothing, 1)
10
   -- runState (stabilize 'a') 3
11 | -- => (Just 'a', 0)
```

```
12
13
   genRanking :: Ticket -> State Ranking Ranking
14
   genRanking t = do
15
       r <- get
16
       put (updateRanking t r)
       r' <- get
17
18
       return r'
19
   -- runState (genRanking "a") []
20
      => ([Rank {title = "a", visitors = 1}],[Rank {title =
21
       "a", visitors = 1}])
      runState (genRanking "a") [Rank "b" 1, Rank "a" 1]
22
   -- => ([Rank {title = "a", visitors = 2}, Rank {title = "b",
23
       visitors = 1}], [Rank {title = "a", visitors = 2}, Rank
       \{title = "b", visitors = 1\}])
```

Si nous tentons de les combiner en tant que Category, c'est impossible car le second type de genRanking, Ranking, n'est pas le même que le premier type de stabilize, Counter.

Il en va de même pour les Monad. En effet >>= a le type suivant :

```
1 (>>=) :: m a -> (a -> m b) -> m b
```

Et nous avons vu que State était considéré comme une Monad avec son premier paramètre de type, State s. Ainsi State Ranking et State Counter sont deux types distincts et >>= nécessite deux Monad du même type.

La différence entre les Arrows et les Monads est que nous pouvons uniquement manipuler le type de sortie d'une Monad alors que nous pouvons manipuler le type d'entrées et le type de sortie d'un Arrow. C'est ce qui les rend plus composable que les Monads.

Il nous faut donc combiner une State Monad pour conserver l'état et un Arrow pour la composition.

Kleisli arrows: fusion des Monads et des Arrows Nous obtenons un Kielsi Arrow [11] à d'un Monad et d'un Arrow, ce qui va nous permettre d'obtenir un calcul qui va dépendre de son état. Node devient alors inutile puisque Kleisli implante déjà les typeclass Arrow et Monad.

Ils sont déclarés de la manière suivante :

```
newtype Kleisli m a b = Kleisli { runKleisli :: a -> m b }
```

Kleisli représente donc une fonction prenant une valeur et renvoyant une valeur dans un type ayant un paramètre.

Si nous mettons côte-à-côte runKleisli, genRanking et stabilize, nous nous rendons compte que Kleisli est une généralisation.

```
1 stabilize :: a -> State Counter (Maybe a)
2 genRanking :: Ticket -> State Ranking Ranking
3 runKleisli :: a -> m b
```

L'instance Category de Kleisli est définie de la manière suivante :

```
instance Monad m => Category (Kleisli m) where
id = Kleisli return
(Kleisli f) . (Kleisli g) = Kleisli (\b -> g b >>= f)
```

Le premier type paramétrique de Kleisli doit être une Monad. Comme nous l'avons vu pour la déclaration de l'instance Monad de State, nous fixons le premier type paramétrique pour que ça corresponde au nombre de type paramétriques attendu, ici, 2.

id, ligne 2, appel le constructeur de Kleisli avec l'équivalent monadique de la fonction identité, à savoir return.

La fonction de composition, (.), ligne 3, extrait les fonctions f et g des constructeurs Kleisli. Il crée ensuite une nouvelle valeur Kleisli qui est composée d'une *lambda expression* attendant un argument qui sera appliqué à g. La valeur résultante sera une Monad, il faut donc la passer à g en utilisant >>=.

Comme pour l'instance Category de Kleisli, l'instance Arrow fixe son premier type paramétrique qui est une Monad.

```
instance Monad m => Arrow (Kleisli m) where
arr f = Kleisli (return . f)
first (Kleisli f) = Kleisli (\ ~(b,d) -> f b >>= \c ->
    return (c,d))
second (Kleisli f) = Kleisli (\ ~(d,b) -> f b >>= \c ->
    return (d,c))
```

arr attend un argument, une fonction f et construit Kleisli en mettant dans une Monad, via return, le résultat de f.

first récupère la fonction f de Kleisli et construit un nouveau Kleisli à l'aide d'une lambda expression qui attend une pair (b, d). b est appliqué à f et sa valeur est extraite de la Monad résultante pour être placé dans c. return encapsule une paire contenant le résultat produit, c, et la valeur d qui est inchangé.

second est construite comme first mais dans l'ordre inverse au niveau des paires.

Nous reprennons nos types précédents, sans Node qui est devenu inutile avec Kleisli:

```
data Rank = Rank { title :: String, visitors :: Int }
    deriving (Show, Eq)

type Ticket = String
type Counter = Int
type Ranking = [Rank]
```

Pour que nos noeuds soient conformes à Kleisli, nous encapsulons les versions monadiques dans le constructeur de Kleisli.

```
updateRanking :: Ticket -> Ranking -> Ranking
5
   updateRanking t r = case b of
6
                             []
                                          -> a ++ [Rank t 1]
                                          -> sortBy (flip compare
7
                             (x : xs)
                                 'on' visitors) (Rank t (1 +
                                 visitors x) : a ++ xs)
8
        where (a, b) = break (\ (Rank i _) \rightarrow i == t) r
   stabilize :: Kleisli (State Counter) a (Maybe a)
10
11
   stabilize = Kleisli (\e -> get >>= \i ->
                                                if i < 2
12
                                                 then put (i + 1)
                                                    >> return
                                                    Nothing
13
                                                 else put 0 >>
                                                     return (Just
                                                     e))
```

Comme nous l'avons vu, Kleisli prend pour premier type paramétrique une Monad, State Ranking pour genRanking et State Counter pour stabilize, selon qu'ils doivent maintenir l'état d'un Ranking ou d'un Counter. Kleisli attend ensuite, comme tout Arrow, un type d'entrée, Ticket et a, ainsi qu'un type de sortie, Ranking et Maybe a. Ce qui implique que runKleisli aura les types suivants:

```
1
  Kleisli {\tt m}
                                        b
                                                   -- generique
2
   runKleisli ::
                             a ->
                                       m b
3
  Kleisli (State Ranking) Ticket
                                        Ranking
                                                   -- genRanking
4
                             Ticket -> State Ranking Ranking
   runKleisli ::
5
  Kleisli (State Counter) a
                                        (Maybe a) -- stabilize
   runKleisli ::
                             a ->
                                        Maybe a
```

La composition ne peut plus se faire selon les fonctions classiques comme >>> puisque les contextes, ici Kleisli (State Ranking) et Kleisli (State Counter), sont différents.

```
stabilizedRanking :: Kleisli (State (Ranking, Counter))
       Ticket (Maybe Ranking)
2
   stabilizedRanking = Kleisli stabilizedRanking'
3
   stabilizedRanking' :: Ticket -> State (Ranking, Counter)
4
       (Maybe Ranking)
   stabilizedRanking, e = do
5
       (ir, is) <- get
6
7
       let (rv, rs) = runState (runKleisli genRanking e) ir
8
       let (sv, ss) = runState (runKleisli stabilize rv) is
9
       put (rs, ss)
10
       return sv
```

Notre Monad stocke un état qui est une paire comprennant les états des deux noeuds le composant, Ranking et Counter.

Nous récupérons et séparons les deux états ligne 6.

Nous ajoutons, ligne 7, le nouveau Ticket e en appliquant e au noeud genRanking, via runKleisli genRanking e. Nous obtenons un State Monad que nous évaluons avec l'état Ranking de la Monad du niveau supérieur, via runState (runKleisli genRanking e)ir.

Nous faisons la même opération avec **stabilize** et ses fonctions respectives, ligne 9.

Nous changeons l'état de la Monad du niveau supérieur avec les nouveaux états, ligne 9.

Enfin nous renvoyons la valeur produite sv, ligne 10, par l'évaluation du noeud stabilize, ligne 8.

Cette composition est coûteuse car nous devons définir nous-même la sémantique d'évaluation qui n'est pas propre à ces deux noeuds en particulier.

Ce qui entraîne une forte duplication qui ne va faire que s'accroître de composition en composition. Le mécanisme ne passe pas à l'échelle puisque la paire sera de plus en plus grande en fonction des composition.

Ce mécanisme est adhoc est non pérein.

Modélisation avec du rythme Pour modéliser la notion de rythme, nous pouvons encapsuler les noeuds précédents dans de nouveaux types, mais comme nous l'avons, la composition n'en serait que plus difficile.

3.4 Introduction des Heterogeneous-Arrows

L'idée de base est de prendre 2 types et d'en générer un 3ème, nous pouvons décrire le typeclass de la manière suivante :

```
class HeterogeneousArrow x y z where
(>*>) :: x a b -> y b c -> z a c
```

HeterogeneousArrow est un typeclass qui se base sur trois types : x, y et z. Il possède un opérateur, >*>, qui combine deux types dont les paramètres sont composables dans un troisième.

Cette définition est trop générale, en effet, cela nous laisse la possibilité de définir n'importe quel z en fonction de x et de y. Nous devons mettre en évidence que z dépend du couple x et y. Pour cela nous utilisons les dépendances fonctionnelles, ou functional dependencies.

```
class HeterogeneousArrow x y z | x y -> z where (>*>) :: x a b -> y b c -> z a c
```

L'instance la plus triviale est lorsque x et y sont de même type et qu'il est composable, au sens qu'il implante l'instance de Category :

```
1 instance (Category x) => HeterogeneousArrow x x x where
2 f >*> g = g . f
```

Nous définissons ainsi que les Category ne sont qu'un cas particulier de HeterogeneousArrow. Dans ce cas, >*> équivault à la composition, (.), de Category.

Nous définissons l'instance Kleisli (State s) de Heterogeneous Arrow de la manière suivante :

```
1
  instance Heterogeneous Arrow (Kleisli (State s)) (Kleisli
      (State s')) (Kleisli (State (s, s'))) where
2
  f >*> g = Kleisli (\e -> do
3
                            (ir, is) <- get
4
                            let (rv, rs) = runState (runKleisli
                               f e) ir
5
                            let (sv, ss) = runState (runKleisli
                               g rv) is
6
                            put (rs, ss)
7
                            return sv)
```

Nous avons utilisé une méthode similaire pour stabilizedRanking. Il y a deux différences : d'une part les Kleisli sont paramétrées, d'autre part, nous nous assurons de manière générique que le type d'entrée de la seconde Kleisli est bien du type de sortie de la première.

stabilizedRanking devient donc:

```
stabilizedRanking :: Kleisli (State (Ranking, Counter))
    Ticket (Maybe Ranking)
stabilizedRanking = genRanking >*> stabilize
```

stabilizedRanking en est réduit à sa forme la plus simple car c'est HeterogeneousArrow qui a la charge de la difficulté de la composition.

Nous rajoutons à présent une notion de rythme. Elle prendra la forme de deux types encapsulés, via newtype, il s'agit simplement pour le compilateur de distinquer deux types.

Le type ${\tt Fast}$, avec son constructeur ${\tt F}$, est déstiné à encapsuler ${\tt genRanking}$. Slow contient ${\tt stabilize}$.

```
newtype Fast s i o = F (Kleisli (State s) i o)
newtype Slow s i o = S (Kleisli (State s) i o)

encStabilize :: Slow Counter a (Maybe a)
encStabilize = S stabilize

encGenRanking :: Fast Ranking Ticket Ranking
encGenRanking = F genRanking
```

Fast et Slow n'ayant pas d'instance de HeterogeneousArrow, il faut en définir une pour pouvoir les composer :

Comme nous le voyons ci-dessus, Fast et Slow n'apportent aucune donnée, elles ne sont là que pour distinguer deux valeurs de même type qui n'ont pas la même signification au sein d'un programme.

Nous voyons ici que composer deux traitements, dont un lent donnera un traitement lent.

stabilizedRanking est donc définie de la manière suivante :

```
stabilizedRanking :: Slow (Ranking, Counter) Ticket (Maybe
Ranking)
stabilizedRanking = encGenRanking >*> encStabilize
```

4 Conclusion

Nous arrivons donc à modéliser des traitements générants des flux de natures et de rythmes différents grâce aux *Heterogeneous-Arrow*.

Il fallait généraliser la composition pour obtenir une table de correspondance entre les différents éléments.

Même si notre méthode résout des problèmes de compositions, elle se base sur un ensemble de paires, ce qui peut nuire à la lisibilité et à la manipulation. Une des pistes d'amélioration est de considérer les états comme des collections hétérogènes, ou heterogeneous collections.

Références

- 1. André, C. : Representation and analysis of reactive behaviors : A synchronous approach (1996)
- 2. Ashcroft, E.A., Wadge, W.W. : Lucid a formal system for writing and proving programs. SIAM J. Comput. 5(3), 336–354 (1976)
- Benveniste, A., Bournai, P., Gautier, T., Le Guernic, P.: SIGNAL: a data flow oriented language for signal processing. Rapport de recherche RR-0378, INRIA (1985)
- Berry, G., Cosserat, L.: The esterel synchronous programming language and its mathematical semantics. In: Brookes, S., Roscoe, A., Winskel, G. (eds.) Seminar on Concurrency, Lecture Notes in Computer Science, vol. 197, pp. 389–448. Springer Berlin Heidelberg (1984)
- Caspi, P., Pilaud, D., Halbwachs, N., Plaice, J.A.: Lustre: A declarative language for real-time programming. In: Proceedings of the 14th ACM SIGACT-SIGPLAN Symposium on Principles of Programming Languages. pp. 178–188. POPL '87, ACM, New York, NY, USA (1987)
- Dennis, J., Fosseen, J., Linderman, J.: Data flow schemas. In: Ershov, A., Nepomniaschy, V.A. (eds.) International Symposium on Theoretical Programming, Lecture Notes in Computer Science, vol. 5, pp. 187–216. Springer Berlin Heidelberg (1972)
- Elliott, C.: Functional implementations of continuous modeled animation. In: Proceedings of the 10th International Symposium on Principles of Declarative Programming. pp. 284–299. PLILP '98/ALP '98, Springer-Verlag, London, UK, UK (1998)

- Elliott, C., Hudak, P.: Functional reactive animation. In: Proceedings of the Second ACM SIGPLAN International Conference on Functional Programming. pp. 263–273. ICFP '97, ACM, New York, NY, USA (1997)
- 9. Elliott, C., Schechter, G., Abi-Ezzi, S.: MediaFlow, a framework for distributed integrated media. Tech. Rep. SMLI TR-95-40, Sun Microsystems Laboratories (1995)
- Elliott, C., Schechter, G., Yeung, R., Abi-Ezzi, S.: Tbag: A high level framework for interactive, animated 3d graphics applications. In: Proceedings of the 21st Annual Conference on Computer Graphics and Interactive Techniques. pp. 421– 434. SIGGRAPH '94, ACM, New York, NY, USA (1994)
- Hughes, J.: Generalising monads to arrows. Sci. Comput. Program. 37(1-3), 67– 111 (May 2000)
- Kahn, G.: The semantics of simple language for parallel programming. In: IFIP Congress. pp. 471–475 (1974)
- 13. Launchbury, J., Peyton Jones, S.: State in haskell. LISP and Symbolic Computation 8(4), 293–341 (1995)
- 14. Marlow, S.: Haskell 2010 language report (2010)
- Nilsson, H., Courtney, A., Peterson, J.: Functional reactive programming, continued. In: Proceedings of the 2002 ACM SIGPLAN Haskell Workshop (Haskell'02).
 pp. 51–64. ACM Press, Pittsburgh, Pennsylvania, USA (Oct 2002)
- Strachey, C.: The varieties of programming language. Tech. Rep. PRG-10, Oxford University (March 1973)
- 17. Thies, W., Karczmarek, M., Amarasinghe, S.: Streamit: A language for streaming applications. In: Horspool, R. (ed.) Compiler Construction, Lecture Notes in Computer Science, vol. 2304, pp. 179–196. Springer Berlin Heidelberg (2002)
- Wadler, P.: Comprehending monads. In: Proceedings of the 1990 ACM Conference on LISP and Functional Programming. pp. 61–78. LFP '90, ACM, New York, NY, USA (1990)
- 19. Wan, Z.: Functional Reactive Programming for Real-Time Reactive Systems. Ph.D. thesis, Department of Computer Science, Yale University (December 2002)